



VQA SYSTEM

Đinh Bùi Khánh Huy – 523H00136

Nguyễn Quốc Hưng – 523H00135

Nguyễn Đông Quân – 523H0171



Overview

- ▶ Introduction
- ▶ Metrics
- ▶ Model A1, A2, B1, B2
- ▶ Kết quả & đánh giá model
- ▶ RLHF/DPO
- ▶ Các phương pháp khác





Introduction

Introduction to VQA (Visual Question Answering)

- Bài toán kết hợp Computer Vision và Natural Language Processing
- Đầu vào: Hình ảnh + Câu hỏi
- Đầu ra: Câu trả lời chính xác
- Yêu cầu: hiểu nội dung ảnh và ngữ nghĩa câu hỏi
- Ứng dụng: trợ lý AI, phân tích hình ảnh, tìm kiếm thông minh



DATASET

- link Hugging face:
<https://huggingface.co/datasets/uitnlp/OpenViVQA-dataset>
- link Kaggle:
<https://www.kaggle.com/datasets/windy261203/openvivqa>
- Bộ dữ liệu OpenViVQA chứa hơn 11.000 hình ảnh với hơn 37.000 cặp câu hỏi-câu trả lời

Metrics

Exact Match Accuracy

- So sánh trực tiếp với ground-truth
- Chuẩn hóa: lowercase, bỏ khoảng trắng
- Đúng hoàn toàn $\rightarrow 1$
- Khác 1 ký tự $\rightarrow 0$

Ưu điểm: phản ánh nhiều đáp án đúng

Nhược điểm: chỉ so khớp chuỗi (không hiểu ngữ nghĩa)



Metrics

Đánh giá câu trả lời dài

BLEU

- So khớp n-gram (1–4)
- Ưu: Nhanh, phổ biến
- Nhược: Không hiểu ngữ nghĩa

ROUGE-L

- Dựa trên chuỗi con chung dài nhất (LCS)
- Ưu: Đánh giá độ bao phủ nội dung
- Nhược: Dễ “ăn điểm” nếu câu dài

METEOR

- Có stemming + synonym
- Ưu: Gần với đánh giá con người
- Nhược: Tính toán phức tạp



Metrics

Đánh giá ngữ nghĩa & nâng cao

BERTScore

- So sánh embedding (cosine similarity)
- Ưu: Hiểu ngữ nghĩa, ngữ cảnh
- Nhược: Tốn tài nguyên

Xu hướng: chuyển từ so khớp từ → hiểu ngữ nghĩa



Models

A1

Encoder-Fusion-LSTM

A2

Encoder-Fusion-Transformer

B1

Zero-shot dựa trên Qwen2-VL-2B

B2

Finetuning dựa trên Qwen2-VL-2B

Cơ chế chung VQA (A1, A2)

- Input: Image + Question
- Kiến trúc: Encoder – Fusion – Decoder

Pipeline:

Image → Vision Encoder

Question → Text Encoder

→ Fusion → Reasoning → Decoder → Answer

Fusion (Multimodal Encoding):

- Ghép nối trực tiếp 49 token ảnh và token câu hỏi thành một chuỗi dài.
- Sử dụng một tầng Dense + LayerNorm để tạo ngữ cảnh chung.



Model A1

Ưu điểm

- Kiến trúc đơn giản, dễ triển khai
- Huấn luyện nhẹ, ổn định
- Tận dụng tốt mô hình pretrained (ResNet, PhoBERT)


Nhược điểm

- Bottleneck: nén toàn bộ thông tin → mất chi tiết
- LSTM khó song song → chậm
- Kém hiệu quả với câu dài / câu hỏi phức tạp

Hyperparameters

- Embed size: 512
- Hidden size: 512
- Decoder layers: 2
- Dropout: 0.3

Fusion: Concat theo chiều sequence



Model A2

Ưu điểm

- Cross-Attention: tập trung đúng vùng ảnh theo từng từ
- Song song hóa tốt → huấn luyện nhanh trên GPU
- Không bottleneck → giữ được nhiều thông tin hơn
- PhoBERT)


Nhược điểm

- Tốn tài nguyên (RAM, compute)
- Dễ overfit với dữ liệu nhỏ

Hyperparameters

- Embed size: 512
- Hidden size: 512
- Decoder layers: 4
- Attention heads: 8
- Dropout: 0.1

Fusion: Concat theo chiều sequence



Qwen2-VL

Mô hình VLM (Vision-Language Model) mạnh
3 phiên bản:

- 2B: nhẹ, tiết kiệm tài nguyên
- 7B: cân bằng
- 72B: mạnh, cho tác vụ phức tạp

Chung Vision Encoder (ViT
~675M params)

Kiến trúc & Công nghệ
Dynamic Resolution

- Xử lý ảnh nhiều kích thước
- Giữ chi tiết tốt hơn

M-RoPE

- Kết hợp vị trí: text (1D) + ảnh (2D) + video (3D)
- Hiểu không gian & thời gian tốt hơn

Tối ưu cho dữ liệu đa phương thức

Tính năng nổi bật

- Hiểu ảnh, tài liệu (OCR, DocVQA)
- Xử lý video dài (20 phút – 1 giờ)
- Agent AI (điều khiển thiết bị)
- Hỗ trợ đa ngôn ngữ (có tiếng Việt)

Mạnh trong các tác vụ thực tế phức tạp

B1 Zero-shot

- Dựa trên Qwen2-VL-2B (pretrained + instruction-tuned). Không cần fine-tune → vẫn trả lời được.
- Ý tưởng: dùng tri thức có sẵn của mô hình

Thông số

- ~2B params
- Zero-shot (không train lại)

Ưu điểm

- Hiểu ảnh + OCR + suy luận tốt
- Linh hoạt, đa ngôn ngữ (có tiếng Việt)

Nhược điểm

- Trả lời có thể chung chung
- Tốn VRAM hơn A1/A2



B2 Fine tune

Mô hình B2 (Finetuning VQA)

- Dựa trên Qwen2-VL-2B
- Khác B1: có fine-tune (SFT) trên OpenViVQA

Mục tiêu: tối ưu cho VQA tiếng Việt

Kiến trúc

LoRA

- Fine-tune nhẹ (không update toàn bộ model)
- Giữ tri thức gốc + học thêm domain
- ♦ Quantization 4-bit

Giảm VRAM, chạy được trên GPU nhỏ

Hyperparameters

- LoRA: $r=16$, $\alpha=32$, dropout=0.05
- LR: $2e-4$ (cosine)
- Batch size: 1 (grad acc = 16)
- Steps: 1500, fp16

Đánh giá

Ưu điểm

- Trả lời đúng format, chính xác hơn B1
- Phù hợp VQA tiếng Việt


Nhược điểm

- Tốn thời gian train
- Có nguy cơ overfit




Kết quả

Loss — a1




loss A1

Loss — a2



loss A2

So sánh hiệu năng các mô hình VQA trên OpenViVQA



Metrics của 4 models

ĐÁNH GIÁ

Training Result (A1 vs A2)

- A1: Val Loss = 3.54
- A2: Val Loss = 2.38

A2 học nhanh hơn, hiệu quả hơn

Overfitting (A2)

- Train loss ↓ 0.85
- Val loss ~ 2.4 (không giảm)

→ A1 ổn định hơn (gap ~0.6)

→ A2 cần regularization (dropout, early stopping)

So sánh hiệu năng (4 models)

B2 (Fine-tune) – tốt nhất

- Accuracy: 14%
- ROUGE-L: 61.8
- BERTScore: 85.6

A2 > A1 (Transformer > LSTM)

- Accuracy: 6% vs 1%

B1 (Zero-shot)

- Accuracy: 0%
- Nhưng semantic cao (ROUGE, BERTScore)

Insight

- Transformer > LSTM (hiểu quan hệ tốt hơn)
- Fine-tuning → cải thiện mạnh hiệu năng (B2 >> B1)

Accuracy chưa đủ


- Zero-shot có thể đúng nghĩa nhưng sai format

DPO

Giai đoạn 1: SFT (B2_SFT)
Train trên OpenViVQA (30K samples)
LoRA (~1.6%) + fp16

Giai đoạn 2: DPO (B2_DPO)
Dữ liệu: (question, chosen, rejected)
Chosen = ground-truth
Rejected = output model

DPO (KẾT QUẢ VÀ PHÂN TÍCH)



Nguyên nhân

- Data preference nhỏ (~190 mẫu)
- Rejected gần đúng → tín hiệu yếu
- Overfit, lệch khỏi SFT
- Output lệch format VQA

Kết luận

- DPO cần data tốt + nhiều hơn
- SFT vẫn hiệu quả hơn trong setting này

CÁC PHƯƠNG PHÁP CẢI THIẾN KHÁC

Chain-of-Thought (CoT)

- Yêu cầu model suy luận từng bước thay vì trả lời ngay

◆ Cách dùng

- Prompt: “Quan sát → liệt kê → kết luận”

Lợi ích

- Giảm lỗi logic, đếm sai
- Hiểu tốt quan hệ trong ảnh

→ Giúp câu trả lời chính xác hơn

Test-Time Augmentation (TTA)

- Tạo nhiều biến thể ảnh khi inference
- Model dự đoán trên từng ảnh

- Majority Voting

- Chọn đáp án xuất hiện nhiều nhất

- Lợi ích

- Tăng accuracy (~2–5%)
- Giảm nhiễu, sai số ngẫu nhiên

Data Augmentation

- Image Augmentation
 - Crop, rotate, blur
 - Thay đổi ánh sáng (color jitter)
- Text Augmentation
 - Paraphrase câu hỏi

Lợi ích

- Tăng robustness
- Tránh overfitting



thank
you